國立陽明交通大學

統計學研究所

碩士論文

Institute of Statistics

National Yang Ming Chiao Tung University

Master's Thesis

# 工具變量維度不足下之時間序列因果推論

# Time-Series Causal Inference under Underspecified Instruments

研 究 生： 曾澤宇 (Tse-Yu Tseng)

指導教授： 高竹嵐 (Chu-Lan Kao)

中華民國 一一五年六月

June 2026

# 工具變量維度不足下之時間序列因果推論

# Time-Series Causal Inference under Underspecified Instruments


研 究 生： 曾澤宇　　Student： Tse-Yu Tseng

指導教授： 高竹嵐 博士　　Advisor： Dr. Chu-Lan Kao


國立陽明交通大學

統計學研究所

碩士論文

A Thesis

Submitted to Institute of Statistics

College of Science

National Yang Ming Chiao Tung University

in Partial Fulfillment of the Requirements

for the Degree of

Master of Science

in

Statistics

June 2026

Taiwan, Republic of China

中華民國 一一五年六月

# 誌　謝

首先，我要謝謝竹嵐老師對於我的研究付出的關心及提點。在我琢磨的過程中給我想法，並對於我的顧慮及疑惑加以解答，使我的研究目標清晰。祝老師身體健康，事事順利，做研究的過程中一帆風順。

同時父母親也在我這麼多年的學習生涯中不斷幫助我，不只給與我物質上得富足，也在精神上給予支撐。對於我的決定及目標都十分支持，謝謝你們。

曾澤宇 於

國立陽明交通大學 統計學研究所

中華民國 一一五年六月

# 工具變量維度不足下之時間序列因果推論

學生：曾澤宇　　指導教授：高竹嵐 博士

國立陽明交通大學
統計學研究所

## 摘　要

工具變量（IV）方法為現代因果推論中處理內生性與未觀測混淆的重要工具。隨著時間序列資料在經濟與科學研究中的廣泛應用，基於向量自我迴歸（VAR）模型的 IV 方法逐漸成為研究動態因果關係的重要框架。然而，經典 IV 理論通常依賴於工具變量數量不少於內生變數數量的識別條件，此一假設在實證分析中往往難以滿足，導致模型處於欠識別（under-identification）或工具不足（under-specified）情境。本文聚焦於 VAR 模型下工具變量維度不足的問題，探討其對因果效應識別與推論的影響，並發展相應的識別策略與統計方法，以提升 IV 方法在高維且受限資訊環境中的實用性與穩健性。

**關鍵字：工具變量、向量自我回歸模型、工具不足、因果效應、時間序列、因果圖**

**Time-Series Causal Inference under Underspecified Instruments**

Student : Tse-Yu Tseng Advisor: Dr. Chu-Lan Kao

Institute of Statistics
National Yang Ming Chiao Tung University

## Abstract

Instrumental variable (IV) methods are important tools in modern causal inference for addressing endogeneity and unobserved confounding. With the increasing use of time series data in economics and scientific research, IV methods based on vector autoregressive (VAR) models have gradually become an important framework for studying dynamic causal relationships. However, classical IV theory usually relies on the identification condition that the number of instrumental variables is no less than the number of endogenous variables. This assumption is often difficult to satisfy in empirical applications, leading to under-identification or underspecified settings.

This thesis focuses on the problem of insufficient instrumental variable dimensions in VAR models. It investigates the impact of this dimensional deficiency on the identification and inference of causal effects, and develops corresponding identification strategies and statistical methods. The goal is to improve the applicability and robustness of IV methods in high-dimensional environments with limited information.

**Keywords: Instrumental Variables, Vector Autoregressive Model, Under-specified Instruments, Causal Inference, Time Series, DAGs**

# 目錄


中文摘要 ..... i

英文摘要 ..... ii

目錄 ..... iii

圖目錄 ..... vi

表目錄 ..... vii

第一章 緒論 ..... 1

第二章 文獻探討 ..... 3

2.1 工具變量法 ..... 3

2.2 VAR 模型 ..... 5

2.2.1 時間序列上的工具變量法 ..... 6

2.2.2 序列實驗下之工具變量選擇方法 ..... 7

第三章 方法論 ..... 9

3.1 問題設定 ..... 9

3.1.1 時間序列系統與符號 ..... 9

3.1.2 工具維度不足的設定 ..... 10

3.2 時間序列工具變量架構 ..... 11

3.2.1 VAR 表示與基本假設 ..... 11

3.2.2 為何不能直接套用 i.i.d. IV ..... 12

3.2.3 時間圖與 block structure ..... 12

3.3 低維投影架構 ..... 13
3.3.1 由完整參數到局部子參數 ..... 13
3.3.2 局部子問題之表示 ..... 14
3.4 Sequential selection 機制 ..... 14
3.4.1 候選資料子集合 ..... 14
3.4.2 以 cosine distance 為基礎之評分 ..... 15
3.5 全域參數重組 ..... 16
3.5.1 局部可行集合 ..... 16
3.5.2 全域可行集合 ..... 16
3.5.3 點重建 ..... 16
3.6 方法流程摘要 ..... 18
第四章 模擬實驗 ..... 21
4.1 評估指標 ..... 21
4.1.1 模擬與實驗參數設定 ..... 22
4.2 基準設定下的估計結果比較 ..... 26
4.3 逐輪重建與 Projection Coverage ..... 27
4.4 敏感性分析 ..... 28
第五章 實際場景下之方法適配性 ..... 31
5.1 資料來源與角色配置 ..... 31
5.2 結果變數、解釋變數與工具變量之建構 ..... 33
5.2.1 結果變數 $Y_t$ ..... 33
5.2.2 高維交通向量 $X_t$ ..... 33
5.2.3 工具變量子集合 $I_1, I_2, I_3$ 的建構 ..... 34
5.3 資料尺度與對齊方式 ..... 37

5.4 為何本文方法較適合此資料場景 ..... 37
第六章 結論與未來方向 ..... 39
參考文獻 ..... 43
Appendix 附錄 ..... 45
.1 資料示例表格 ..... 45

# 圖目錄

圖 1 Full time graph . . . . . 10

圖 2 基準設定下的全域估計誤差 . . . . . 27

圖 3 逐輪重建表現與累積投影空間覆蓋程度 . . . . . 28

圖 4 Underidentification 程度的敏感性分析 . . . . . 29

圖 5 時間序列依賴強度的敏感性分析 . . . . . 30

# 表目錄

表 1　基準設定下各方法之全域估計誤差比較 . . . . . 26

表 2　Underidentification 程度之敏感性分析設定 . . . . . 28

表 3　不同時間序列依賴強度下 Proposed method 的全域估計誤差摘要。 . . . . 30

表 4　資料來源與模型角色配置 . . . . . 32

表 5　工具變量子集合 $I_1, I_2, I_3$ 之來源、時間特徵與變數構建 . . . . . 35

表 6　各資料塊之維度與基本特徵 . . . . . 36

表 7　$Y_t$ 部分資料示例 . . . . . 46

表 8　$X_t$ 部分資料示例 . . . . . 47

表 9　$I_1$ 部分資料示例 . . . . . 48

表 10　$I_2$ 部分資料示例 . . . . . 49

表 11　$I_3$ 部分資料示例 . . . . . 50

# 第一章、緒論

本研究的發想，源自於部分實驗研究在成本限制下，採取連續且小規模的實驗設計，並藉由投影方法 [1] 整合各次實驗所提供的片段資訊，以形成對整體參數的完整推論。此一思路使本文進一步思考：在現實世界的觀測資料中，問題往往不僅來自實驗成本的限制，更在於資料本身的維度結構即可能構成工具變量法應用上的主要障礙，並且現實的觀測資料時常受序列結構影響，導致 i.i.d 方法難以應用。特別是當不同資料來源僅能提供局部資訊，而單一資料集合又不足以支撐完整識別時，如何整合這些分散且片面的訊息，便成為一項重要而具挑戰性的問題。因此，若能將多個來源的觀測資料，例如不同觀測站所蒐集之資料，以合適的模型處立後再適當結合並共同推論，是否能在非實驗資料的情境下，達到某種程度上類似實驗設計中近似 i.i.d. 環境所能獲得的推論效果，便成為本研究的核心動機之一。

本研究聚焦於時間序列資料中的因果推論問題。相較於橫斷面資料，時間序列資料中的變數之間通常具有更複雜的動態依賴關係，除了可能同時存在直接與間接影響之外，亦常伴隨跨期傳遞、動態回饋以及潛在混淆等現象，使得傳統方法難以有效識別真實的因果效應。在此情境下，工具變量（Instrumental Variables, IV）方法因具有處理未觀測混淆因子的能力，而成為因果推論中的重要工具。隨著研究的發展，工具變量方法已逐步延伸至不同資料型態與模型架構，其中亦包括時間序列資料。以時間序列為例，已有研究針對動態系統中的工具變量識別問題提出相應方法，如 Thams 等人所建立之時間序列工具變量模型 [2]。然而，這類方法在實務應用上仍受到若干核心假設與維度條件的限制，尤其當工具變量的數量不足以支撐內生變數的識別時，亦即模型處於 under-identified 或 dimension mismatch 的情形下，其適用性便受到明顯限制。

有鑑於此，本文欲探討的核心問題為：當可取得之工具變量維度不足時，是否仍能透過方法上的調整與結構資訊的利用，使工具變量方法在時間序列因果模型中持續發揮辨識能力。具體而言，本文關注於多組低維度工具變量的整合與重構，嘗試透過投影、子空間分解與結構性限制等方式，將原本僅能提供局部識別資訊的低維工具集合加以組合，進一步提升其對高維內生變數的解釋能力，並改善因果效應的可識別性。

因此，本文旨在對既有工具變量方法進行延伸與優化，使其能適用於工具變量維度受限的情境，並進一步應用於具有複雜動態依賴關係的時間序列模型之中。透過此一研究架構，本文期望拓展工具變量法在實務資料分析中的適用範圍，使其在更貼近現實資料條件、且未必具備理想識別結構的情況下，仍能維持穩健的因果推論能力。

# 第 二 章、文獻探討

## 2.1 工具變量法

工具變量法（Instrumental Variables, IV）是處理內生性問題的重要方法，常用於當解釋變數與誤差項相關，因而使普通最小平方法（OLS）估計產生偏誤與不一致時的因果效應識別。其基本思想為：尋找一個與內生解釋變數相關，但不直接影響結果變數、且不與結構誤差項相關的外生變數，作為工具變量，以抽取解釋變數中的外生變異，進而識別目標參數。

工具變量法的思想可追溯至 [3]，其於探討供需聯立關係時，已使用具有現代工具變量精神的識別方式，以解決價格與數量同時決定所造成的內生性問題。其後，[4] 作為早期 2SLS 相關文獻之一，推動了工具變量估計在聯立方程模型中的形式化發展。

考慮線性結構方程

$$Y = X\beta + u, \tag{2.1}$$

其中 $Y$ 為結果變數，$X$ 為可能內生的解釋變數，$\beta$ 為欲估計之參數，$u$ 為誤差項。若存在工具變量矩陣 $Z$，滿足

$$E(Z'u) = 0, \tag{2.2}$$

且 $Z$ 與 $X$ 具有足夠相關性，則可利用矩條件

$$E\big[Z'(Y - X\beta)\big] = 0 \tag{2.3}$$

來識別 $\beta$。在此架構下，IV 不僅是一種估計技術，更是一種依賴識別條件的因果推論方法。

在方法論上，[5] 將工具變量估計置於更完整的統計推論框架下，系統討論了識別、估計效率與過度識別限制檢定等問題，奠定了傳統 IV 理論的重要基礎。其後 [6] 將此類正交條件推廣為廣義動差法（Generalized Method of Moments, GMM），使 IV 可被視為 GMM 的特例，並使異質變異與更一般的矩條件設定得以納入分析，因而大幅擴展了 IV 方法的適用範圍。

除了聯立方程模型中的傳統用途外，工具變量法在現代因果推論中亦具有核心地位。在潛在結果架構下，[7] 指出，當工具變量滿足獨立性、排除限制、相關性與單調性等條件時，IV estimand 可被解釋為受工具影響而改變處理狀態之族群的局部平均處理效果（Local Average Treatment Effect, LATE）。即受到工具變量影響而改變處理狀態之族群的平均因果效應。此一結果使工具變量法不再僅被視為修正內生性的估計工具，而是與潛在結果架構下的因果參數解釋緊密結合。

[8] 進一步從自然實驗的角度整理了 IV 的識別思想，強調工具變量的可信性來自制度背景、行為機制與研究設計，而非僅來自形式上的估計公式。因此，現代文獻對 IV 的關注，除了估計本身之外，也包含工具變量是否滿足相關性（relevance）與外生性（exogeneity）兩項核心條件。前者要求工具變量能有效解釋內生變數的變異，後者則要求工具變量僅能透過內生變數影響結果變數，而不與結構誤差相關。

綜合而言，工具變量法的文獻發展可由兩個面向理解。第一，早期文獻處理的是聯立性與內生性所導致的識別困難，並建立了 IV 與 2SLS 的基本估計架構 [3, 4, 5]；第二，後續研究將 IV 納入更一般的矩條件與因果推論框架中，說明其識別對象與參數意義 [6, 7, 8]。因此，工具變量法已由早期聯立方程中的技術性估計工具，逐步發展成現代因果推論中兼具識別、估計與推論意義的重要方法。

## 2.2 VAR 模型

向量自回歸模型（Vector Autoregression, VAR）是多變量時間序列分析中最具代表性的模型之一，其主要特徵在於將系統中的所有變數皆視為內生變數，並以各變數自身的落後值以及其他變數的落後值，來共同描述系統的動態演化。相較於傳統大型聯立方程總體模型需事先施加較多理論限制，VAR 模型以較少的先驗結構假設，提供了描述多變數動態關係的彈性框架。此一方法通常被認為由 Sims 所系統性提出，並成為現代總體計量與金融時間序列分析的重要基礎 [9, 10]。

設 $Y_t = (Y_{1,t}, Y_{2,t}, \ldots, Y_{K,t})^\top$ 為一個包含 $K$ 個變數的平穩時間序列向量，則一個 $p$ 階 VAR 模型可寫為

$$Y_t = A_1 Y_{t-1} + A_2 Y_{t-2} + \cdots + A_p Y_{t-p} + \varepsilon_t, \tag{2.4}$$

其中 $A_1, \ldots, A_p$ 為 $K \times K$ 的係數矩陣，$\varepsilon_t$ 為隨機誤差向量。此模型的核心概念，在於以系統內全部變數的歷史資訊來解釋當前狀態，因此能有效捕捉變數間的動態交互影響、延遲效果與傳遞機制 [10, 11]。

Sims 在其經典研究中指出，傳統總體計量模型往往對變數施加過多當期結構限制，容易導致模型錯置問題；相對而言，VAR 模型以資料本身的動態關係為核心，將每個變數視為系統內共同演化的一部分，因而能作為分析總體經濟波動的一種較具彈性的實證工具 [9]。此一觀點不僅改變了總體經濟實證分析的建模方式，也奠定了後續脈衝反應函數（Impulse Response Function, IRF）與預測誤差變異分解（Forecast Error Variance Decomposition, FEVD）等分析工具的發展基礎 [10]。

在實際應用上，VAR 模型廣泛使用於總體經濟、金融市場、貨幣政策傳遞、國際貿易以及因果動態分析等領域。一方面，其模型形式相對一般、估計上可藉由逐方程最小平方法進行；另一方面，其配套之 IRF、FEVD、Granger 因果關係檢定與結構識別

工具，也使 VAR 成為分析動態因果傳播機制的重要方法 [10, 11]。

### 2.2.1 時間序列上的工具變量法

工具變量法在獨立同分布資料中，是處理內生性與潛在混淆的重要方法；然而在時間序列資料中，若直接套用傳統 IV 方法，通常無法得到一致估計。其主要原因在於時間序列具有記憶性，變數之間的相關不僅來自當期結構，也會受到過去狀態影響，因此某一滯後工具變量即使與當期處理變數相關，也可能透過更早期的共同祖先影響結果變數，進而破壞傳統 IV 所需的排除限制。

針對此問題，[2] 以 VAR 時間序列模型為背景，討論在存在未觀測混淆時如何識別處理變數對結果變數的因果效應。作者指出，時間序列 IV 的核心困難在於必須對過去造成的額外路徑進行校正，因此不能僅沿用 i.i.d. 情形下的 2SLS 或 GMM 設定，而需重新建構適合動態資料的識別方程。

在方法上，該文結合圖模型與時間序列結構，證明在 VAR($p$) 過程下可利用 full time graph 與其邊際化圖來判斷條件獨立關係，進而建立有效的工具變量識別方式。作者提出兩種主要方法：其一是條件式工具變量（conditional IV, CIV），藉由控制適當的過去資訊來阻斷不需要的路徑；其二是 nuisance IV（NIV），透過加入額外的 nuisance regressors，一併處理由過去傳遞而來的干擾影響。此外，該文也指出，時間序列中的識別條件與傳統 i.i.d. IV 不同。在某些 VAR(1) 情形下，識別條件與系統參數矩陣的 Jordan form 有關，甚至可能在工具變量維度少於解釋變數維度時，仍藉由多個時間落後的工具變量達成識別。此結果顯示，時間序列結構本身可提供額外的識別資訊，也使時間序列上的工具變量法發展出不同於傳統 IV 的理論特徵。

綜合而言，時間序列上的工具變量法並非僅是傳統 IV 在動態資料上的直接延伸，而是必須進一步考慮過去依賴、圖結構與識別條件後，才能建立一致的因果估計方法。[2] 的研究提供了系統性的理論基礎，也為後續時間序列因果推論與 underidentified IV

問題奠定了重要方向。

### 2.2.2 序列實驗下之工具變量選擇方法

傳統工具變量法通常要求工具變量的數量至少不小於內生處理變數的維度，亦即需滿足 just-identified 或 overidentified 的設定，才能對因果效應進行完整識別。然而，在高維處理變數的應用中，此條件往往過於嚴格。例如在基因表現、微生物組或轉錄體等問題中，研究者關注的處理變數通常是高維的，但實際可用的干預手段或工具變量數量卻十分有限，因此形成所謂 underspecified 的工具變量問題。[1] 即針對此一情形，探討如何在工具變量維度不足的情況下，仍有效估計高維因果效應。

該文指出，在線性 IV 模型下，當工具變量維度小於處理變數維度時，完整的因果效應向量通常無法由單一次實驗識別；然而，仍可識別因果效應在工具所張成子空間上的正交投影。換言之，雖然無法直接恢復整體因果效應 $\beta$，但可先估計其在當前 instrumented subspace 上的可識別部分，並且此投影估計量具有一致性與漸近常態性。此結果提供了一種在 underidentified IV 設定下仍可進行有效推論的基本途徑。

在此基礎上，[1] 進一步提出：若研究者可以進行多輪實驗，且每一輪使用不同的工具變量子集合，則可將各次實驗所得之部分投影估計加以整合，重建出如同「同時使用所有工具變量」時所能獲得的整體投影估計。也就是說，單次實驗雖僅能識別因果效應的一部分，但藉由多組不同工具所提供的子空間資訊，可以逐步擴張已識別的方向，進而提升對完整因果效應的掌握程度。

此外，該文更進一步將此想法發展為順序式工具變量選擇（sequential instrument selection）方法。作者考慮在實驗成本有限、且每次只能使用少量工具變量的情況下，如何於多輪實驗中依序選出最具資訊性的工具子集，以最大化最終對因果效應的識別程度。其方法利用工具之間的相似性與成本函數，在資訊增益與實驗代價之間做權衡，從而逐步選取最有效的工具變量組合。

除了估計方法外，[1] 亦討論如何判斷哪些因果效應分量已被可靠識別，以及在尚未完全識別時，如何對未識別部分的誤差給出上界。此一設計使研究者即使在有限輪實驗之後無法完全恢復整體因果效應，仍能了解目前估計中哪些部分較可信、哪些部分仍存在不確定性。

綜合而言，[1] 的研究將傳統 IV 問題由「是否能一次完整識別」推進到「如何在工具維度不足時逐步累積可識別資訊」的框架下思考。此文不僅補足了 underidentified IV 文獻中較少被處理的高維情形，也為後續從多組低維工具變量資訊重建高維因果效應的研究提供了方法論基礎。

# 第 三 章、方法論

本章說明本文所提出之 projected time IV 方法。本文所欲處理的問題同時包含兩個層面：其一，資料本身來自時間序列系統，因此不能直接沿用 i.i.d. 線性工具變量方法；其二，即使在時間序列架構下可建立有效的 identifying equations，可用工具變量仍可能僅以多組低維子集合的形式存在，而無法由單一工具集合一次性支撐高維因果參數之完整識別。基於此，本文的方法論可分為兩個主要部分：首先，在時間序列工具變量架構下建立有效的動態識別條件；其次，在工具維度不足時，以低維投影、逐步選取與全域重組的方式，恢復對高維參數的推論能力。

## 3.1 問題設定

### 3.1.1 時間序列系統與符號

如圖 1 所示，本文考慮一組多變量時間序列

$$S := [S_t]_{t\in\mathbb{Z}} = \left[I_t^\top,\, H_t^\top,\, X_t^\top,\, Y_t^\top\right]_{t\in\mathbb{Z}}^\top,$$

其中

- $I := [I_t]_{t\in\mathbb{Z}}$ 為工具變量過程，
- $X := [X_t]_{t\in\mathbb{Z}}$ 為內生解釋變數過程，
- $Y := [Y_t]_{t\in\mathbb{Z}}$ 為結果變數過程，

- $H := [H_t]_{t\in\mathbb{Z}}$ 為未觀測之潛在混淆過程。

在工具變量部分，本文進一步假設

$$I_t := \left[(I_t^1)^\top, (I_t^2)^\top, \ldots, (I_t^k)^\top\right]^\top,$$

其中 $I^1, \ldots, I^k$ 表示 $k$ 組子工具過程。令 $d_I, d_H, d_X, d_Y$ 分別表示各子過程於單一期點之維度，並記

$$d = d_I + d_H + d_X + d_Y.$$

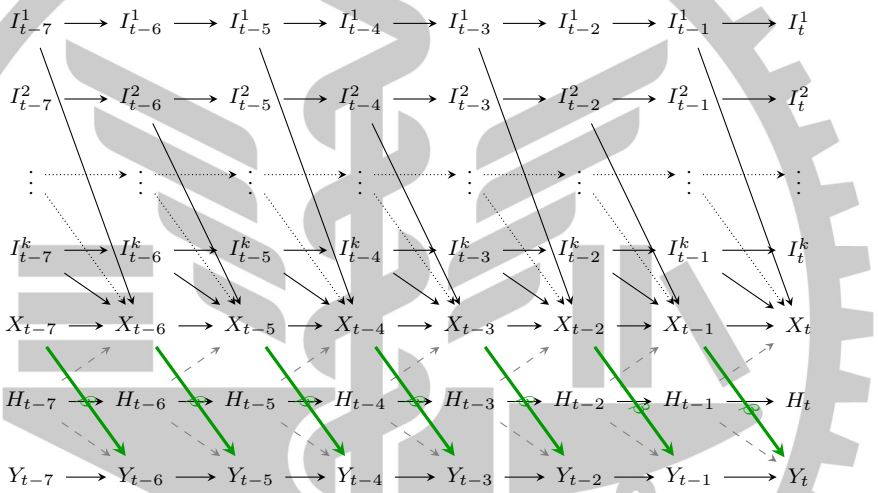


圖 1: Full time graph

### 3.1.2 工具維度不足的設定

設整體工具變量過程 $I_t$ 由 $k$ 組子工具過程

$$I_t := \left[(I_t^1)^\top, (I_t^2)^\top, \ldots, (I_t^k)^\top\right]^\top$$

所組成，則其總維度可表示為

$$d_I = \sum_{j=1}^{k} d_{I^j},$$

其中 $d_{I^j}$ 表示子工具過程 $I^j$ 的維度。本文假設整體工具變量之總維度滿足

$$d_I \geq d_X,$$

但對任意單一子工具過程 $I^j$，皆有

$$d_{I^j} < d_X, \qquad j = 1, \ldots, k.$$

換言之，雖然整體工具變量在維度上可能足以支撐高維參數之識別，但任一單一工具子集合本身皆不足以單獨識別完整的高維解釋變數。此一設定正是本文欲處理之核心問題：如何在多組低維工具子集合下，逐步累積對高維參數的識別資訊。

## 3.2 時間序列工具變量架構

### 3.2.1 VAR 表示與基本假設

本文假設整體過程 $S$ 為一平穩向量自我迴歸過程。亦即，存在係數矩陣

$$A_1, \ldots, A_p \in \mathbb{R}^{d \times d}$$

使得對所有 $t \in \mathbb{Z}$，

$$S_t = A_1 S_{t-1} + \cdots + A_p S_{t-p} + \varepsilon_t, \tag{3.1}$$

其中 $\{\varepsilon_t\}_{t \in \mathbb{Z}}$ 為 i.i.d. 創新項，具有有限二階動差，且參數矩陣滿足穩定性條件，使過程為弱平穩。進一步地，本文採用 Gaussian VAR 設定，假設

$$\varepsilon_t \sim N(0, \Gamma),$$

其中 $\Gamma$ 為對角矩陣。

### 3.2.2 為何不能直接套用 i.i.d. IV

在此架構下，本文關心的是處置過程 $X$ 對結果過程 $Y$ 的因果效果。然而，若直接將 i.i.d. 線性 IV 方法套用至時間序列資料，通常無法得到一致估計。其原因在於，時間序列中的工具、處置與結果不僅透過當期關係相連，亦會透過過去狀態、共同祖先與動態傳播路徑形成額外依賴。因此，即使某工具在靜態情形下看似滿足排除限制，於時間序列中仍可能因未對過去資訊進行調整而失效。

換言之，時間序列中的工具變量方法必須建立在對動態路徑與過去依賴加以校正之 identifying equations 上，而非僅沿用 i.i.d. 架構下之靜態 moment condition。

### 3.2.3 時間圖與 block structure

為描述此一動態結構，本文採用時間圖表示，如圖 1。所謂 full time graph，係指將各時間點上的 $I_t, H_t, X_t, Y_t$ 皆視為圖上節點；若某個係數區塊在第 $k$ 期落後上非零，則在圖上加入由時間 $t-k$ 指向時間 $t$ 的有向邊。此一圖形將整個動態系統沿時間展開，使各影響路徑得以明確表示。

在本文的主要設定中，進一步假設 VAR(1) 之係數矩陣具有下列 block structure：

$$A_1 = \begin{pmatrix} \alpha_{I,I} & 0 & 0 & 0 \\ 0 & \alpha_{H,H} & 0 & 0 \\ \alpha_{X,I} & \alpha_{X,H} & \alpha_{X,X} & \alpha_{X,Y} \\ 0 & \alpha_{Y,H} & \beta^\top & \alpha_{Y,Y} \end{pmatrix}. \tag{3.2}$$

此一結構表示：工具過程 $I$ 不受其他子過程影響；$I$ 不直接進入 $Y$ 之方程，亦不直接進入潛在混淆過程 $H$ 之方程；但潛在混淆 $H$ 可同時影響 $X$ 與 $Y$。

在此條件下，結果變數方程可寫為

$$Y_t = \alpha_{Y,Y} Y_{t-1} + \beta^\top X_{t-1} + \eta_t, \tag{3.3}$$

其中

$$\eta_t = \alpha_{Y,H} H_{t-1} + \varepsilon_t^Y. \tag{3.4}$$

因此，$\beta$ 即為本文所欲識別之目標因果參數。

## 3.3 低維投影架構

### 3.3.1 由完整參數到局部子參數

即使已能於時間序列中建立有效之 identifying equations，可用工具過程之有效維度仍可能不足以支撐完整高維參數之識別。亦即，當 $X_t \in \mathbb{R}^p$ 為高維內生向量，而工具僅能對其中部分方向提供資訊時，完整參數 $\beta \in \mathbb{R}^p$ 仍可能無法由單一工具集合一次性恢復。

因此，本文不直接於原始高維空間中要求完整識別，而是引入低維投影架構。對第 $m$ 個子問題，定義

$$\theta_m = P_m \beta, \qquad m = 1, \ldots, M, \tag{3.5}$$

其中 $P_m \in \mathbb{R}^{d_m \times p}$ 為已知投影矩陣，且 $d_m < p$。故 $\theta_m \in \mathbb{R}^{d_m}$ 可視為完整參數 $\beta$ 在第 $m$ 個低維子空間中的表示。

### 3.3.2 局部子問題之表示

相應地，原模型中的線性項可改寫為

$$X_t^\top \beta = X_{m,t}^\top \theta_m + W_{m,t}^\top \gamma_m, \tag{3.6}$$

其中 $X_{m,t}$ 表示與目標子參數 $\theta_m$ 相對應之低維處置表示，$W_{m,t}$ 表示其餘部分，$\gamma_m$ 為相應之輔助參數。故第 $m$ 個局部子結構可表示為

$$Y_t = X_{m,t}^\top \theta_m + W_{m,t}^\top \gamma_m + u_t. \tag{3.7}$$

在此設定下，不同工具子集合、不同滯後資訊組合或不同局部投影方向，皆可分別對不同低維子參數提供局部識別資訊。

## 3.4 Sequential selection 機制

### 3.4.1 候選資料子集合

在高維情形下，低維子問題本身亦不宜由研究者事先完全固定。若可用之工具子集合、滯後資訊集合或候選子空間數量龐大，則一次納入所有候選集合不僅不具可行性，亦可能造成資訊重複與估計效率下降。

基於此，本文引入 sequential selection 的觀點，將低維子問題之建構視為一個逐步搜尋過程。形式上，設

$$\mathcal{A} = \{A_1, \ldots, A_K\}$$

表示所有候選資料子集合，其中每一個 $A_k$ 可對應於某一組工具子向量、某一組落後結構、某一組局部投影矩陣，或其組合。

### 3.4.2 以 cosine distance 為基礎之評分

令 $\mathcal{S}_{r-1}$ 表示第 $r-1$ 輪以前已被選取之候選集合索引，則第 $t$ 輪的選取可寫為

$$A_{k_r} = \arg \max_{A_k \in \mathcal{A} \setminus \mathcal{S}_{r-1}} \text{Score}(A_k \,;\, \mathcal{S}_{r-1}), \tag{3.8}$$

其中 $\text{Score}(A_k \,;\, \mathcal{S}_{r-1})$ 用以衡量候選集合 $A_k$ 相對於目前已選集合的額外資訊量。

本文以 cosine distance 作為 sequential selection 的主要評分依據。若以某種特徵表示 $\phi(A_k)$ 描述候選子集合 $A_k$ 所對應之資訊方向，則候選集合 $A_k$ 與已選集合 $A_j$ 之間的差異程度可定義為

$$d_{\cos}(A_k, A_j) = 1 - \frac{\phi(A_k)^\top \phi(A_j)}{\|\phi(A_k)\|_2 \, \|\phi(A_j)\|_2}. \tag{3.9}$$

當兩者資訊方向越相近時，$d_{\cos}(A_k, A_j)$ 越小；反之，若兩者對應於較不同的識別方向，則 $d_{\cos}(A_k, A_j)$ 越大。

因此，候選集合的整體分數可寫為

$$\text{Score}(A_k \,;\, \mathcal{S}_{r-1}) = \frac{1}{|\mathcal{S}_{r-1}|} \sum_{j \in \mathcal{S}_{r-1}} d_{\cos}(A_k, A_j). \tag{3.10}$$

若需同時考慮資訊增益與使用成本，亦可更一般地寫為

$$\text{Score}(A_k \,;\, \mathcal{S}_{r-1}) = \lambda \, \text{InfoGain}(A_k \,;\, \mathcal{S}_{r-1}) + (1-\lambda) \frac{1}{|\mathcal{S}_{r-1}|} \sum_{j \in \mathcal{S}_{r-1}} d_{\cos}(A_k, A_j), \tag{3.11}$$

其中 $\lambda \in [0,1]$ 為權重參數, $\text{InfoGain}(\cdot)$ 會做為評判子集合在全空間中得到剩餘資訊的函數。

## 3.5 全域參數重組

### 3.5.1 局部可行集合

在每一輪選取到新的候選子集合後，本文便針對相應之低維子問題建立其局部可行參數集合，記為

$$\Theta_m \subseteq \mathbb{R}^{d_m}.$$

由於每一個低維參數皆滿足 $\theta_m = P_m\beta$，故第 $m$ 個子問題實際上對原始高維參數空間施加了一組限制，其對應之可行集合可寫為

$$\mathcal{B}_m = \{\beta \in \mathbb{R}^p : P_m\beta \in \Theta_m\}. \tag{3.12}$$

### 3.5.2 全域可行集合

當共有 $M$ 個已選取之低維子問題時，完整高維參數之全域可行集合定義為

$$\mathcal{B}_{\text{global}}^{(M)} = \bigcap_{m=1}^{M} \mathcal{B}_m = \bigcap_{m=1}^{M} \{\beta \in \mathbb{R}^p : P_m\beta \in \Theta_m\}. \tag{3.13}$$

隨著 sequential selection 的進行，新的局部限制將持續加入，故全域可行集合亦會逐步收縮，從而累積更多對原始高維參數之識別資訊。

### 3.5.3 點重建

前述全域可行集合提供了一個集合形式的識別描述；然而，在模擬實驗與實際估計中，本文仍需由各局部子問題所提供的投影資訊重建一個高維點估計量 $\hat{\beta}$。因此，本節進一步說明本文如何由多個低維投影估計量 $\hat{\theta}_m$ 組合得到全域參數估計。

對第 $m$ 個已選取之局部子問題，假設其提供了完整參數 $\beta$ 在投影矩陣 $P_m$ 所對應子空間上的估計量

$$\hat{\theta}_m \approx P_m \beta, \qquad m = 1, \ldots, M.$$

若多個局部子問題所涵蓋的投影方向足以共同支撐原始高維空間，則可將全域參數 $\beta$ 視為同時滿足多組近似線性限制的未知向量。基於此，本文以最小平方法形式定義全域重組估計量：

$$\hat{\beta} = \arg\min_{b \in \mathbb{R}^p} \sum_{m=1}^{M} \left\| \hat{\theta}_m - P_m b \right\|_2^2. \tag{3.14}$$

式 (3.14) 的直觀意義是：尋找一個高維向量 $b$，使其在每一個局部投影方向上的表示 $P_m b$，都盡可能接近該局部子問題所估計出的投影參數 $\hat{\theta}_m$。因此，$\hat{\beta}$ 可被視為所有已選取低維投影資訊的全域整合結果。

進一步地，令

$$\hat{\theta} = \begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \\ \vdots \\ \hat{\theta}_M \end{pmatrix}, \qquad P = \begin{pmatrix} P_1 \\ P_2 \\ \vdots \\ P_M \end{pmatrix},$$

則式 (3.14) 可改寫為

$$\hat{\beta} = \arg\min_{b \in \mathbb{R}^p} \left\| \hat{\theta} - P b \right\|_2^2. \tag{3.15}$$

當堆疊後的投影矩陣 $P$ 具有足夠的秩時，該問題具有閉式解

$$\hat{\beta} = \left( P^\top P \right)^\dagger P^\top \hat{\theta}, \tag{3.16}$$

其中 $(\cdot)^\dagger$ 表示 Moore–Penrose 廣義逆。若 $P^\top P$ 非奇異，則式 (3.16) 退化為一般最小平方法解。

在本文的模擬實驗中，所報告的全域估計誤差即根據上述重組後的點估計量 $\hat{\beta}$ 計算：

$$\text{Error} = \left\| \hat{\beta} - \beta_0 \right\|_2, \tag{3.17}$$

其中 $\beta_0$ 為資料生成過程中的真實因果參數。由此可知，前述局部可行集合與全域可行集合提供了識別結構上的解釋，而本節所定義的 $\hat{\beta}$ 則提供了實際可用於數值比較與模擬評估的點估計量。

## 3.6 方法流程摘要

綜合上述時間序列調整、低維投影、逐步選取與全域重組的流程，本文方法可摘要如下。

總結而言，本文所提出之 projected time IV 方法，係在時間序列工具變量的動態識別架構下，透過低維投影、逐步選取與集合重組的方式，處理工具維度不足時對高維因果參數之推論問題。

**Algorithm 1** Projected Time-Series IV with Sequential Low-Dimensional Reconstruction

**Input:** Observed time-series sample $\{(Y_t, X_t, I_t^1, \ldots, I_t^k)\}_{t=1}^T$;

conditioning set $B_t$ constructed from past information;

candidate instrument blocks $\mathcal{A} = \{A_1, \ldots, A_K\}$;

maximum number of selected rounds $M$.

**Output:** Reconstructed global estimator $\hat{\beta} \in \mathbb{R}^p$.

**Residualization.** Regress $Y_t$, $X_t$, and each candidate block $A_k$ on the conditioning set $B_t$, and obtain residualized variables

$$\tilde{Y}_t, \qquad \tilde{X}_t, \qquad \tilde{Z}_{k,t}, \quad k = 1, \ldots, K.$$

Equivalently, in matrix form,

$$\tilde{Y} = M_B Y, \qquad \tilde{X} = M_B X, \qquad \tilde{Z}_k = M_B Z_k,$$

where $M_B = I - P_B$ is the residual-maker associated with $B_t$.

**Initial estimator.** Construct an initial estimator $\beta^{(0)}$ from a baseline IV/CIV procedure based on the residualized system, and form

$$u_t = \tilde{Y}_t - \tilde{X}_t^\top \beta^{(0)}.$$

**Initialization.** Set

$$\mathcal{S}_0 = \emptyset.$$

**for** $m = 1, \ldots, M$ **do**

  **if** $m = 1$ **then**

    Choose the first candidate block $A_{k_1}$ according to a preset initialization rule.

  **else**

    **for** each $A_k \in \mathcal{A} \setminus \mathcal{S}_{m-1}$ **do**

      Compute

$$\mathrm{Score}(A_k; \mathcal{S}_{m-1}) = \frac{1}{|\mathcal{S}_{m-1}|} \sum_{j \in \mathcal{S}_{m-1}} d_{\cos}(A_k, A_j),$$

where

$$d_{\cos}(A_k, A_j) = 1 - \frac{\phi(A_k)^\top \phi(A_j)}{\|\phi(A_k)\|_2 \, \|\phi(A_j)\|_2}.$$

    **end for**

    Select

$$k_m = \arg \max_{A_k \in \mathcal{A} \setminus \mathcal{S}_{m-1}} \mathrm{Score}(A_k; \mathcal{S}_{m-1}).$$

  **end if**

  **Local moment construction.** For the selected block $A_{k_m}$, let $\tilde{Z}_m$ denote its residualized instrument matrix. Construct

$$f_t^{(m)} = u_t \, \tilde{Z}_{m,t}.$$

  **HAC covariance estimation.** Estimate

$$\hat{S}_m = \sum_{\ell=-L}^{L} K\left(\frac{\ell}{L}\right) \hat{\Gamma}_m(\ell).$$

Algorithm 1 (continued)

Set the weighting matrix

$$W_m = \hat{S}_m^{-1}.$$

**Projection matrix construction.** Let $Z_m$ be the sample design matrix formed by $\tilde{Z}_{m,t}$. Define

$$P_m = Z_m \big(Z_m^\top W_m Z_m\big)^\dagger Z_m^\top W_m.$$

**Projected local estimator.** Compute

$$\hat{\beta}^{(m)} = \big(\tilde{X}^\top P_m \tilde{X}\big)^\dagger \tilde{X}^\top P_m \tilde{Y}.$$

**Low-dimensional parameter restriction.** Let

$$Q_m \in \mathbb{R}^{d_m \times p}, \qquad d_m < p,$$

and define

$$\theta_m = Q_m \beta.$$

The local estimator induces

$$\Theta_m \subseteq \mathbb{R}^{d_m},$$

and hence

$$\mathcal{B}_m = \{\beta \in \mathbb{R}^p : Q_m \beta \in \Theta_m\}.$$

Update

$$\mathcal{S}_m = \mathcal{S}_{m-1} \cup \{k_m\}.$$

**end for**

**Global reconstruction.** Compute

$$\hat{\beta} = \arg\min_{b \in \mathbb{R}^p} \|b\|_2^2 \quad \text{subject to} \quad Q_m b \in \Theta_m, \qquad m = 1, \ldots, M.$$

Equivalently,

$$\mathcal{B}_{\text{global}}^{(M)} = \bigcap_{m=1}^{M} \mathcal{B}_m.$$

**return** $\hat{\beta}$ and $\mathcal{B}_{\text{global}}^{(M)}$.

# 第 四 章、模擬實驗

## 4.1 評估指標

為了衡量各方法對 full-dimensional causal effect 的重建能力，本文使用全域估計誤差作為主要評估指標。令 $\beta_0$ 為真實因果參數，$\hat{\beta}$ 為估計結果，則全域估計誤差定義為：

$$\mathrm{Err}(\hat{\beta}) = \|\hat{\beta} - \beta_0\|_2.$$

此指標衡量估計值與真實參數之間的歐氏距離，數值越小表示方法越能準確重建完整因果效果。

此外，為了檢驗本文方法是否確實透過多輪子實驗逐步累積可識別資訊，本文亦觀察逐輪重建誤差：

$$\mathrm{Err}^{(r)} = \|\hat{\beta}^{(r)} - \beta_0\|_2,$$

其中 $\hat{\beta}^{(r)}$ 表示使用前 $r$ 輪子實驗所得 projected estimates 整合後的估計結果。

最後，本文使用 projection coverage score 衡量累積 projection space 對參數方向的覆蓋程度。令 $\kappa_j^{(r)}$ 表示第 $j$ 個座標方向與前 $r$ 輪累積 projection space 之間的角度，則 coverage score 定義為：

$$C_r(c) = \frac{1}{p+1} \sum_{j=0}^{p} \mathbf{1}\{\kappa_j^{(r)} < c\},$$

其中 $c$ 為角度門檻。Coverage score 越高，表示目前累積的 projection space 越能覆蓋目標參數的不同方向。

### 4.1.1 模擬與實驗參數設定

本節說明本文模擬實驗所採用之參數設定。本文考慮一組高維時間序列工具變量情境，其中內生解釋變數維度固定為

$$p = 10,$$

故完整因果參數 $\beta_0 \in \mathbb{R}^{10}$。在每一次子實驗中，研究者僅能使用一組低維工具變量子集合，且其維度上限記為 $d_{\max}$。因此，單次子實驗僅能提供對 $\beta_0$ 某一局部投影方向的識別資訊，而無法單獨完成對完整十維參數的全域識別。

在本文的模擬中，樣本長度設定為

$$T = 1000,$$

每一組參數設定皆進行

$$M = 500$$

次 Monte Carlo 重複實驗。每一次 Monte Carlo 實驗皆重新生成一組時間序列資料，並分別套用 Proposed method、Random sequential selection、Single-subset IV 與 OLS。本文以 Monte Carlo 重複實驗下的估計誤差分布，評估各方法在有限樣本中的表現。

在實際計算全域估計誤差時，本文將迴歸截距一併納入估計向量中，並設定真實截距為 0。因此，表格中回報之誤差係根據

$$\left\| \begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} - \begin{pmatrix} 0 \\ \beta_0 \end{pmatrix} \right\|_2$$

計算，其中 $\hat{\alpha}$ 為估計截距，$\hat{\beta}$ 為估計之十維因果效果。由於截距項的真值固定為零，此設定主要用於配合實際估計程序中的截距設計。

在資料生成過程方面，本文假設整體系統服從一階向量自我迴歸結構。令 $S_t$ 表示包含工具變量、內生解釋變數、潛在混淆因子與結果變數之整體狀態向量，則其動態可表示為

$$S_t = AS_{t-1} + \varepsilon_t, \qquad \varepsilon_t \sim N(0, \Gamma).$$

其中 $A$ 為時間序列係數矩陣，$\Gamma$ 為創新項的共變異矩陣。為控制時間序列的 persistence 強度，本文先隨機生成一個初始係數矩陣 $A_0$，先將其調整至符合工具變量架構之穩態矩陣後，再將其依照目標 spectral radius 進行縮放：

$$A = \frac{\rho}{\rho(A_0)} A_0,$$

其中 $\rho(A_0)$ 表示 $A_0$ 的 spectral radius，而 $\rho$ 為本文指定的目標時間依賴強度。透過此一設定，可確保不同模擬情境具有可比較的時間序列 persistence。

創新項共變異矩陣 $\Gamma$ 用於控制各變數之間的 contemporaneous dependence 與雜訊強度。本文在每一次 Monte Carlo 實驗中固定資料生成機制的基本結構，並由隨機誤差項產生不同樣本路徑。此設計使得各方法面對相同的內生性與時間依賴結構，因而能夠公平比較不同估計策略的表現。

為了刻畫不同程度的時間依賴性，本文以係數矩陣之 spectral radius

$$\rho(A)$$

控制系統的 persistence 強度，其中較大的 $\rho(A)$ 代表較強的時間序列延續性。在基準設定中，本文採用

$$\rho(A) = 0.8$$

作為主要分析情形，並於敏感性分析中進一步考慮

$$\rho(A) = 0.2,\ 0.5,\ 0.8,\ 0.95$$

等不同設定，以檢驗方法對時間依賴強度的穩定性。

在工具變量設定方面，本文令總工具變量維度為

$$d = 15.$$

由於內生解釋變數維度為 $p = 10$，整體而言工具變量總維度足以提供全域識別所需的資訊。然而，本文的核心限制在於每一次子實驗僅能使用其中一部分工具變量。在基準設定下，本文令

$$d_{\max} = 3, \qquad R = 5,$$

其中 $R$ 表示 sequential selection 所選取之子實驗輪數。故基準設定下的總工具預算為

$$d_{\max} R = 15.$$

此一設計反映本文的核心研究情境：雖然單一輪子實驗只能使用低維工具變量，然而若能透過多輪子實驗逐步累積資訊，則仍可能重建完整的高維因果效果。

在工具維度不足程度的敏感性分析中，本文固定總工具預算為

$$d_{\max} R = 15,$$

並比較以下三組配置：

$$(d_{\max}, R) = (1, 15),\ (3, 5),\ (5, 3).$$

三組設定皆滿足

$$d_{\max} < p = 10,$$

因此每一輪子實驗本身仍為低維且無法單獨識別完整十維參數；然而三者的總工具預算相同，故可用於比較在不同子實驗維度與輪數配置下，本文方法的重建穩定性。

在方法比較方面，本文考慮四種估計策略：

1. **Proposed method**：本文提出之 sequential projected IV 方法；
2. **Random sequential selection**：以隨機方式選取低維工具變量子集合；
3. **Single-subset IV**：僅使用單一低維工具變量子集合進行估計；
4. **OLS**：不使用工具變量，直接以內生解釋變數迴歸結果變數。

其中，Proposed method 與 Random selection 的差異主要在於子集合選擇機制：前者依據本文所提出之 sequential selection 原則選取具有互補性的低維工具變量子集合，後者則不利用此資訊而隨機選取子集合。藉由比較兩者，可進一步檢驗 selection strategy 對全域參數重建的影響。

在數值實作上，本文於每次估計中加入截距項，並在計算估計誤差時一併納入截距誤差。為避免不同變數尺度影響工具變量選擇與投影重建，本文在估計過程中未額外對變數進行標準化，而是使用資料生成過程所產生之原始尺度進行估計。由於所有比較方法皆使用相同資料，因此方法之間仍具有可比較性。

最後，對於每一組參數設定，本文皆進行 Monte Carlo 重複實驗，並以全域估計誤差、逐輪重建誤差與 projection coverage score 作為主要評估指標。此一設計使本文得以同時檢驗：其一，本文方法能否在基準設定下有效重建完整因果參數；其二，當時間序列依賴程度與 underidentification 結構改變時，方法表現是否仍具穩定性。

## 4.2 基準設定下的估計結果比較

本節比較四種方法在基準設定下的表現。第一種為本文提出的 Proposed method，其透過 sequential selection 選擇低維工具變量子集合，並整合多輪 projected estimates 來重建完整 causal effect。第二種為 Random sequential selection，其以隨機方式選擇工具變量子集合。第三種為 Single-subset IV，僅使用單一低維工具變量子集合進行估計。第四種為 OLS，其不使用工具變量，直接以內生解釋變數迴歸結果變數。

表 1 彙整各方法在 Monte Carlo 重複實驗下的全域估計誤差。結果顯示，Proposed method 的平均誤差與中位數誤差皆低於 Random selection、Single-subset IV 與 OLS。這表示本文方法能較有效地利用多輪低維 IV 子實驗所提供的 projected information，進而提升 full-dimensional causal effect 的重建準確度。

Single-subset IV 的誤差明顯較高，說明單一低維工具變量子集合無法充分識別完整的十維因果參數。此結果符合本文設定，因為每一輪子實驗僅能使用 $d_{\max} = 3$ 個工具變量，而內生變數維度為 $p = 10$，因此單次子實驗本身必然不足以完成全域識別。

另一方面，OLS 的誤差高於 Proposed method，顯示在存在潛在混淆的情境下，直接迴歸 $Y$ on $X$ 會受到內生性影響，導致較大的估計偏誤。相較之下，本文方法透過工具變量所提供的外生變異進行估計，因此能有效降低由潛在混淆造成的誤差，同時注意到做 Random seleciton 時由於蒙地卡羅模擬時會有極端情況出現，可能會導致數值爆炸，因此標準差顯著高於其他方法。

表 1: 基準設定下各方法之全域估計誤差比較

| 方法 | 平均誤差 | 中位數誤差 | 標準差 | 第一四分位數 | 第三四分位數 |
|---|---|---|---|---|---|
| Proposed | 0.3450 | 0.3264 | 0.1430 | 0.2359 | 0.4231 |
| Random | 0.6839 | 0.4204 | 2.6467 | 0.3036 | 0.6123 |
| Single subset | 4.5826 | 4.9557 | 0.8105 | 3.8954 | 5.2343 |
| OLS | 0.6119 | 0.6138 | 0.0361 | 0.5885 | 0.6362 |

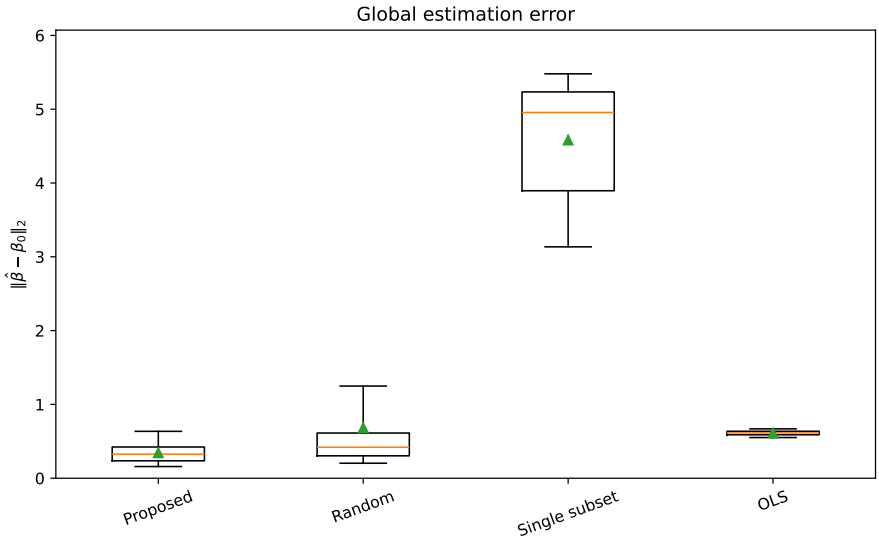



圖 2: 基準設定下的全域估計誤差

## 4.3 逐輪重建與 Projection Coverage

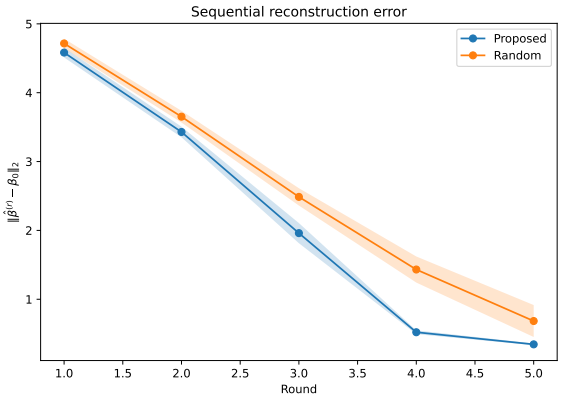
為進一步檢驗本文方法是否能透過多輪子實驗逐步累積資訊，圖 3a 呈現 Proposed method 與 Random selection 在不同輪數下的重建誤差。

由圖 3a 可見，隨著子實驗輪數增加，Proposed method 的估計誤差呈現下降趨勢，表示多輪低維 IV 子實驗確實能夠逐步累積對 $\beta_0$ 的資訊。相較之下，Random selection 雖然也可能因納入更多子實驗而降低誤差，但整體誤差仍高於 Proposed method。此結果說明，在工具變量維度不足的情境下，子集合的選擇策略對全域參數重建具有重要影響。

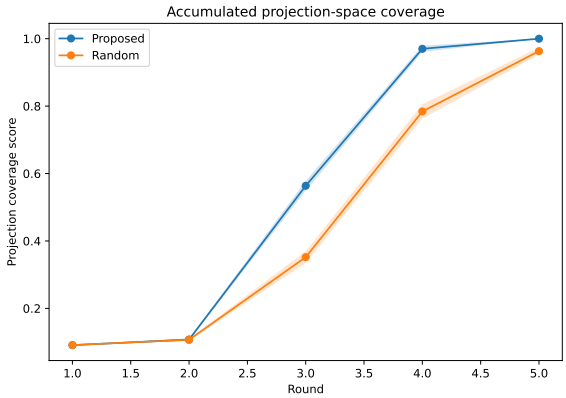
為了說明誤差下降的原因，圖 3b 進一步呈現 projection coverage score 的變化。

圖 3b 顯示，Proposed method 的 projection coverage 明顯高於 Random selection，且隨著輪數增加而穩定上升。這表示本文方法並非僅透過增加子實驗數量改善估計，而是能夠選擇較具互補性的工具變量子集合，使累積 projection space 更快覆蓋目標參數的不同方向。

換言之，本文方法的改善機制在於：每一次低維子實驗雖然只能識別 $\beta_0$ 的某個投




(a) 逐輪重建誤差




(b) 累積 projection-space coverage

圖 3: 逐輪重建表現與累積投影空間覆蓋程度

影方向，但透過適當的 sequential selection，多個 projected estimates 能夠形成互補資訊，進而逐步重建完整因果參數。

## 4.4 敏感性分析

本節進一步檢驗本文方法對 underidentification 程度與時間序列依賴強度的敏感性。首先，本文固定總 IV budget 為 15，並比較三組不同配置：

$$(d_{\max}, R) = (1, 15), (3, 5), (5, 3).$$

三組設定皆滿足 $d_{\max} < p = 10$，因此每一輪子實驗本身仍然無法完整識別十維因果參數。然而，三組設定的總 IV budget 皆為 15，因此可用於檢驗方法在不同低維子實驗配置下的穩定性。

由圖 4 可見，三組設定下的估計誤差皆維持在相近範圍內，表示本文方法對於每

表 2: Underidentification 程度之敏感性分析設定

| 設定 | $d_{\max}$ | 子實驗輪數 $R$ | 總 IV budget $d_{\max}R$ |
|---|---|---|---|
| 高度低維子實驗 | 1 | 15 | 15 |
| 基準設定 | 3 | 5 | 15 |
| 中度低維子實驗 | 5 | 3 | 15 |

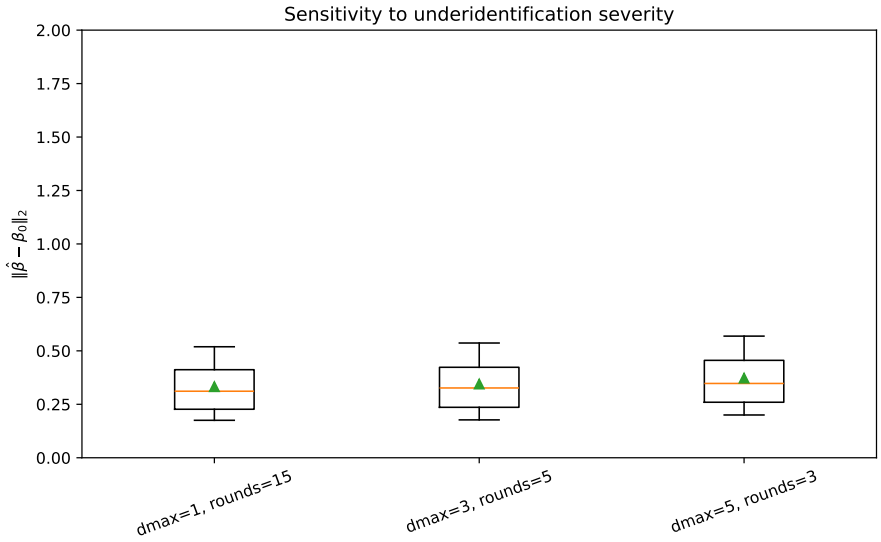



圖 4: Underidentification 程度的敏感性分析

輪子實驗可使用工具變量數量與輪數配置並不高度敏感。即使在 $(d_{\max}, R) = (1, 15)$ 的極低維子實驗設定中，每一輪僅能使用一個工具變量，本文方法仍可透過較多輪數累積 projected information，維持穩定估計表現。

接著，本文檢驗不同時間序列依賴強度下的方法表現。本文考慮 spectral radius：

$$\rho(A) = 0.2, 0.5, 0.8, 0.95.$$

其中較大的 $\rho(A)$ 代表時間序列具有較強的 persistence。

由圖 5 與表 3 可見，隨著 spectral radius 增加，平均誤差與中位數誤差大致呈上升趨勢，表示較強的時間序列 persistence 會增加估計難度。然而，即使在 $\rho(A) = 0.95$ 的設定下，估計誤差仍未出現爆炸，顯示本文方法在強依賴情境下仍具有一定穩定性。

綜合以上結果，本文提出的 sequential projected IV 方法在時間序列工具變量維度不足的情境下展現穩定且有效的估計表現。在基準設定中，Proposed method 的全域估計誤差低於 Random selection、Single-subset IV 與 OLS，說明本文方法能有效利用多個低維 IV 子實驗所提供的 projected information。

逐輪重建結果顯示，隨著納入的子實驗數量增加，估計誤差逐步下降；projection

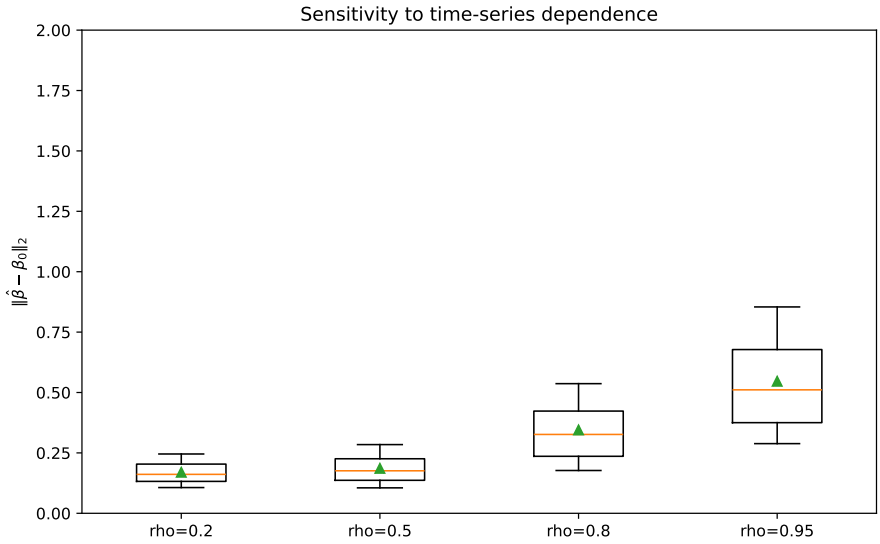



圖 5: 時間序列依賴強度的敏感性分析

coverage 的結果則進一步指出，本文方法能比 Random selection 更快擴張累積 projection space。此結果支持本文方法的核心機制：透過選擇互補的低維工具變量子集合，可以將多個 projected estimates 整合為對 full-dimensional causal effect 的有效重建。

敏感性分析亦顯示，本文方法在不同 underidentification 程度與不同時間序列依賴強度下皆維持穩定表現。整體而言，模擬結果支持本文方法可應用於多組低維工具變量子集合無法單獨識別完整因果參數，但可透過多輪資訊累積重建全域效果的時間序列因果推論情境。

表 3: 不同時間序列依賴強度下 Proposed method 的全域估計誤差摘要。

| 設定 | 平均誤差 | 中位數誤差 | 標準差 | 第一四分位數 | 第三四分位數 |
|---|---|---|---|---|---|
| $\rho = 0.2$ | 0.1699 | 0.1612 | 0.0553 | 0.1321 | 0.2036 |
| $\rho = 0.5$ | 0.1861 | 0.1759 | 0.0691 | 0.1365 | 0.2257 |
| $\rho = 0.8$ | 0.3450 | 0.3264 | 0.1430 | 0.2359 | 0.4231 |
| $\rho = 0.95$ | 0.5466 | 0.5110 | 0.2314 | 0.3752 | 0.6778 |

# 第 五 章、實際場景下之方法適配性

本章旨在說明本文所提出之 projected time IV 方法在真實資料中的適配性。為此，本文使用 Sacramento 地區之交通與氣象資料作為實證場景，藉此展示在真實世界中，當結果變數、解釋變數與工具變量分別來自不同來源，且各資料來源在觀測頻率、時間索引與變數結構上並不完全一致時，為何以低維重組的方式進行推論相較於直接將所有資料粗略聯合後估計會更加適用。

## 5.1 資料來源與角色配置

本文使用之資料可分為兩部分：一為 California Department of Transportation 之 Performance Measurement System（PeMS）交通資料；二為 NOAA 地面氣象站之觀測資料。PeMS 提供固定交通測站在五分鐘尺度下之總流量（Total Flow）、平均速度（Avg Speed）與平均占有率（Avg Occupancy）等資訊；NOAA 資料則提供不同氣象站之天氣觀測值。本文將兩類資料結合，以建立一個「高維交通狀態 $X_t$ – 單一交通結果 $Y_t$ – 多組低維外部工具 $I_1, I_2, I_3$」的時間序列因果推論架構。

在交通資料部分，本文聚焦於 Sacramento 區域內七個交通測站。其中，站點 312745 作為目標站點，用於定義結果變數 $Y_t$；其餘六個測站

316922, 318102, 317802, 317141, 314230, 317013

則作為高維解釋變數 $X_t$ 的來源。於氣象資料部分，本文選取三個 Sacramento 地區 NOAA 測站，分別為 Sacramento AP ASOS、Sacramento McClellan AFB 及 Sacramento

Metro AP，並由此構造三組低維工具變量子集合 $I_1, I_2, I_3$。

表 4 整理本文各資料來源與其在模型中的角色配置。

表 4: 資料來源與模型角色配置

| 資料來源 | 觀測單位 | 模型角色 | 說明 |
|---|---|---|---|
| PeMS 交通資料 | 7 個交通測站 | $X_t, Y_t$ | 目標站點 312745 用於定義結果變數 $Y_t$；其餘六站之流量、速度與占有率組成高維 $X_t$。 |
| NOAA 氣象站 1 | Sacramento AP ASOS | $I_1$ | 提供偏向降水、氣壓與雲層之低維工具變量子集合。 |
| NOAA 氣象站 2 | Sacramento Mc-Clellan AFB | $I_2$ | 提供偏向溫度、濕度、能見度與風速之低維工具變量子集合。 |
| NOAA 氣象站 3 | Sacramento Metro AP | $I_3$ | 提供偏向風向、雲高、濕球溫度、站壓與陣風之低維工具變量子集合。 |

## 5.2 結果變數、解釋變數與工具變量之建構

### 5.2.1 結果變數 $Y_t$

本文以交通站點 312745 作為目標站點，並利用該站五分鐘資料中的平均速度建構壅塞指標 $Y_t$。令 $v_t$ 表示站點 312745 在時間 $t$ 的平均速度，$v_{\text{free}}$ 表示該站之自由流速基準，則本文定義

$$Y_t = \max\left\{0,\ 1 - \frac{v_t}{v_{\text{free}}}\right\}. \tag{5.1}$$

此一指標可直接反映交通速度偏離自由流狀態之程度：當 $v_t$ 接近自由流速時，$Y_t$ 接近 0；當平均速度下降時，$Y_t$ 上升，代表壅塞程度增加，在本文的示範性資料配置中，氣象變數被視為外部擾動來源，本文假設其主要透過周邊交通狀態 $X_t$ 影響目標站點壅塞 $Y_t$。此一假設在正式實證研究中仍需搭配交通機制與額外穩健性檢查加以支持。

### 5.2.2 高維交通向量 $X_t$

本文使用其餘六個交通測站

$$316922,\ 318102,\ 317802,\ 317141,\ 314230,\ 317013$$

於每一五分鐘時間點之交通狀態構成高維交通向量 $X_t$。對每一測站，本文保留三項變數：

- 總流量（Total Flow）
- 平均速度（Avg Speed）
- 平均占有率（Avg Occupancy）

因此，$X_t$ 可表示為

$$X_t = \left(q_{1t}, s_{1t}, o_{1t}, q_{2t}, s_{2t}, o_{2t}, \ldots, q_{6t}, s_{6t}, o_{6t}\right)^\top \in \mathbb{R}^{18}, \tag{5.2}$$

其中 $q_{it}, s_{it}, o_{it}$ 分別代表第 $i$ 個測站於時間 $t$ 的流量、速度與占有率。由於目標站點之壅塞狀態通常與周邊路段的交通條件共同演化，因此將多個鄰近測站之資訊整合為高維向量 $X_t$，更能反映真實交通系統之動態結構。

### 5.2.3 工具變量子集合 $I_1, I_2, I_3$ 的建構

本文所使用之三組工具變量 $I_1, I_2, I_3$ 並非僅在變數內容上彼此不同，更重要的是，它們在資料來源層級即呈現出不同的時間記錄節奏，因此不適合被直接視為一組可同步聯合使用的工具集合。換言之，本研究面對的問題並不只是工具變量來自不同測站，而是這些測站自原始資料開始，便以不同頻率、不同記錄間隔與不同可用時間點提供觀測值。這使得三組工具變量更自然地應被理解為三個彼此互補、但各自不完整的局部資訊來源，而非一個可直接以共同時間索引粗略拼接而成的完整工具矩陣。

具體而言，本文所建構之 $I_1$ 來自 Sacramento AP ASOS，其原始觀測在研究期間內具有相對密集的記錄時間，主要以接近五分鐘的節奏出現，但仍伴隨若干 1 至 4 分鐘與較長間隔的混合情形；$I_2$ 來自 Sacramento McClellan AFB，其資料則主要呈現約二十分鐘左右的記錄節奏；$I_3$ 來自 Sacramento Metro AP，則更接近以一小時為主要觀測間隔。也就是說，三組工具資料的時間尺度並非由本文事後人為設定，而是由原始資料來源本身所決定。對此類資料而言，若直接要求三組工具變量在同一組時間點上同步存在，則勢必需要額外進行強制對齊、重採樣、插補或聚合；而一旦如此處理，原始資料所保留的局部變異、觀測節奏差異與工具子集合之異質性便可能被削弱。

因此，本文並未將 $I_1, I_2, I_3$ 粗略地 union 成單一工具資料塊，而是保留其各自原有的時間索引，並分別將每一筆工具資料對應至最近時間的 PeMS 觀測，以建立對應的

$X_t$ 與 $Y_t$。此一設計反映了本文方法的核心思想：當外部工具資訊是以多組低維、異步且異質的形式存在時，與其先強行壓縮為單一同步集合，不如保留各子集合的原始結構，先分別提取其對高維交通狀態的局部識別資訊，再透過 projected time IV 的重組程序累積對整體參數空間的限制。從這個角度來看，三組工具變量的尺度不一致並不是資料處理上的瑕疵，而正是本文方法在實際資料中具有必要性的直接來源。

除了時間尺度不同之外，本文亦刻意使三組工具變量在欄位配置上互不重疊，避免不同工具子集合只是相同氣象變數在不同站點上的重複觀測。如此一來，$I_1, I_2, I_3$ 不僅在時間上無法自然同步，在資訊內容上也分別對應不同的外部擾動方向。這使得三組工具變量更適合被視為三個低維局部投影問題，而非一個可以直接粗略聯合估計的傳統工具集合。

由表 5可得

$$d_{I_1} = 7, \qquad d_{I_2} = 6, \qquad d_{I_3} = 7,$$

表 5: 工具變量子集合 $I_1, I_2, I_3$ 之來源、時間特徵與變數構建

| 工具集合 | 資料來源 | 主要時間特徵 | 變數內容 |
|---|---|---|---|
| $I_1$ | Sacramento AP ASOS | 以接近五分鐘為主，但夾雜其他較短與較長間隔 | precipitation_5_minute, sea_level_pressure, pressure_3hr_change, sky_condition_baseht, sky_cover_summation_baseht_2, precipitation, precipitation_3_hour |
| $I_2$ | Sacramento Mc-Clellan AFB | 以約二十分鐘記錄節奏為主 | altimeter, relative_humidity, temperature, dew_point_temperature, visibility, wind_speed |
| $I_3$ | Sacramento Metro AP | 以約一小時記錄節奏為主 | wind_direction, ceiling_height, wet_bulb_temperature, station_level_pressure, sky_cover_summation_baseht_1, wind_gust, sky_cover_summation_baseht_3 |

因此三組工具變量總維度為

$$d_I = d_{I_1} + d_{I_2} + d_{I_3} = 20.$$

另一方面，本文高維交通向量 $X_t$ 的維度為

$$d_X = 18.$$

表 6 整理各資料塊之維度與基本特徵。

表 6: 各資料塊之維度與基本特徵

| 資料塊 | 維度 | 時間特徵 | 內容說明 |
|---|---|---|---|
| $Y_t$ | 1 | 五分鐘交通資料 | 由站點 312745 的平均速度建構之壅塞指標。 |
| $X_t$ | 18 | 五分鐘交通資料 | 六個鄰近交通測站之流量、速度與占有率。 |
| $I_1$ | 7 | 依最近時間配對至 PeMS | 偏向降水、氣壓與雲層相關資訊。 |
| $I_2$ | 6 | 依最近時間配對至 PeMS | 偏向溫度、濕度、能見度與風速相關資訊。 |
| $I_3$ | 7 | 依最近時間配對至 PeMS | 偏向風向、雲高、濕球溫度、站壓與陣風相關資訊。 |

## 5.3 資料尺度與對齊方式

在本研究的實際資料結構中，最重要的問題並不在於資料量是否足夠，而在於不同資料來源之間的尺度與對齊方式並不一致。PeMS 交通資料以五分鐘為基本時間粒度，因此 $X_t$ 與 $Y_t$ 均具有一致且高頻的時間索引；然而，NOAA 氣象資料雖然可在研究期間內提供觀測值，其原始記錄時間並不與 PeMS 完全同步，且三個氣象站之可用時間點亦不完全一致。

基於此，本文並未強行要求三組工具變量於相同時間點同步存在，而是對每一筆 NOAA 觀測資料，分別尋找最近時間之 PeMS 記錄，並以此方式將 $I_j$ 與對應之 $X_t$、$Y_t$ 相連結。也就是說，本文實際採用的是「各工具子集合分別與交通資料最近時間對齊」的方式，而非先將三個工具資料源整併為單一完全同步之工具矩陣。此一設計使每組工具變量皆能在其自身可用的時間點上，盡可能保留原始資料所提供的局部訊息。

這一點十分重要。若研究者改採粗略的同步 union 作法，則通常必須先將三組氣象資料整併至共同時間索引，再與五分鐘粒度之 PeMS 資料結合。然而，這樣的作法往往伴隨兩種代價：其一，若僅保留所有工具變量皆同時存在的時間點，則可用樣本將明顯減少；其二，若透過插補、重採樣或再聚合等方式製造同步資料，則原始資料的局部變異與異質性會被削弱。換言之，問題並不是資料在形式上能否被聯合，而是聯合之後是否仍保有原始工具資料中最具價值的資訊結構。

## 5.4 為何本文方法較適合此資料場景

在上述資料結構下，直接將三組工具變量粗略 union 在一起進行估計，並不是最自然的選擇。首先，任一單獨之工具子集合 $I_1$、$I_2$ 或 $I_3$ 皆僅為低維區塊，難以單獨支撐對高維 $X_t$ 的完整識別。其次，雖然三組工具變量之總維度超過 $X_t$ 的維度，但這些資訊並非以同步、同質且可直接聯合的形式給出，而是分散在不同的氣象站、不同的變

數配置與不同的時間對齊條件之中。因此，若將其直接視為單一完整工具集合，實際上等於忽略了這些工具資料最重要的特性：它們本質上是多個彼此互補、但各自不完整的局部識別來源。

本文所提出之 projected time IV 方法在此場景下之所以合適，正是因為它不要求所有工具變量一開始就被壓縮為單一同步資料塊。相反地，本文允許每一組工具變量先於其自身可對齊的時間點上提供局部資訊，再透過低維投影、逐步選取與全域重組的方式，累積對高維交通狀態 $X_t$ 的整體限制。此一作法的優勢，在於它保留了不同工具子集合原始所攜帶的異質資訊方向，也避免了為了形式上的同步而進行過度整併所造成的樣本損失與資訊扭曲。

換言之，本文方法在本實證資料中的價值，並不僅在於處理「工具變量維度不足」這一抽象問題，而在於它更符合真實資料的生成與記錄方式。當外部工具資訊天然呈現為多組低維、異質且不同步的局部來源時，與其先強制將其 union 成單一資料塊，不如保留各子集合的原始結構，再透過重組方式形成對高維參數的整體推論。這正是本文方法在本資料場景下具有實際用途的主要原因。

# 第六章、結論與未來方向

本研究旨在探討時間序列工具變量模型中，當每一次子實驗可使用之工具變量維度不足時，是否仍能透過多組低維工具變量子集合所提供的資訊，重建完整的因果效果。傳統工具變量方法通常要求工具變量數量足以識別內生解釋變數，然而在實務資料中，不同工具變量可能分散於不同資料來源、不同時間區段或不同實驗條件下，使得單一次可用的工具變量子集合維度不足。本文因此提出 sequential projected IV 方法，透過逐輪選擇低維工具變量子集合，取得多個 projected estimates，並將其整合以重建 full-dimensional causal effect。

在模擬設定中，本文令內生解釋變數維度為 $p = 10$，工具變量總維度為 $d_I = 15$。雖然整體工具變量維度大於內生變數維度，但每一輪子實驗至多只能使用 $d_{\max} < p$ 個工具變量，因此單一子實驗本身仍處於 underidentified setting。基準設定採用 $(d_{\max}, R) = (3, 5)$，亦即每輪最多使用三個工具變量，並進行五輪子實驗。本文比較 Proposed method、Random sequential selection、Single-subset IV 與 OLS 四種方法，並以全域估計誤差 $\|\hat{\beta} - \beta_0\|_2$ 作為主要評估指標。

模擬結果顯示，本文提出的方法在基準設定下具有最低的平均估計誤差。Proposed method 的平均誤差為 0.3450，中位數誤差為 0.3264，低於 Random selection、Single-subset IV 與 OLS。Random selection 的平均誤差為 0.6839，且標準差較大，表示隨機選擇工具變量子集合時，估計結果較不穩定。Single-subset IV 的平均誤差高達 4.5826，明顯高於其他方法，說明單一低維工具變量子集合不足以重建完整因果參數。OLS 的平均誤差為 0.6119，高於 Proposed method，表示在存在潛在混淆的情境下，直接使用 OLS 估計會產生較大的偏誤。此結果支持本文方法能有效利用多輪低維 IV 子實驗所提

供的 projected information，提升 full-dimensional causal effect 的重建準確度。

逐輪重建結果進一步顯示，隨著納入的子實驗數量增加，Proposed method 的估計誤差呈現下降趨勢，且整體低於 Random selection。此現象表示，多輪低維子實驗確實能逐步累積對真實參數 $\beta_0$ 的資訊。Projection coverage 的結果亦顯示，本文方法能比 Random selection 更快擴張累積的 projection space，代表本文方法的改善並非僅來自於增加子實驗數量，而是來自於選擇了較具互補性的工具變量子集合。換言之，sequential selection 的核心作用在於提高各輪投影資訊之間的互補性，進而使多個 projected estimates 能有效整合為對完整參數的重建。

在 underidentification 程度的敏感性分析中，本文固定總 IV budget 為 15，並比較 $(d_{\max}, R) = (1, 15), (3, 5), (5, 3)$ 三種配置。結果顯示，本文方法在不同子實驗維度與輪數配置下皆能維持穩定表現。這表示方法並不依賴單一特定的子集合大小，而是能在每輪極低維度但輪數較多，或每輪維度稍高但輪數較少的設定下，透過累積 projected information 重建全域因果參數。

在時間序列依賴強度的敏感性分析中，本文考慮 $\rho(A) = 0.2, 0.5, 0.8, 0.95$ 四種 spectral radius 設定。結果顯示，當 $\rho(A)$ 增加時，估計誤差有上升趨勢；其中 $\rho(A) = 0.2$ 時 Proposed method 的平均誤差為 0.1699，而 $\rho(A) = 0.95$ 時平均誤差上升至 0.5466。此結果表示，較強的時間序列 persistence 會增加估計難度。然而，即使在 $\rho(A) = 0.95$ 的高時間依賴設定下，估計誤差仍維持在可接受範圍內，未出現明顯的誤差爆炸。因此，本文方法在不同程度的平穩時間序列依賴下仍具有一定穩定性，但其有限樣本表現會受到時間序列依賴強度影響。

綜合而言，本文模擬結果支持 sequential projected IV 方法在時間序列工具變量維度不足情境下的有效性。當單一子實驗無法提供足夠工具變量以識別完整因果參數時，本文方法可透過多輪低維工具變量子集合所提供的 projected information，逐步重建 full-dimensional causal effect。相較於隨機選擇子集合或僅使用單一低維子集合，本文方法

能更有效地累積互補資訊，並降低全域估計誤差。

未來研究可從以下幾個方向延伸。首先，本文目前主要透過模擬實驗驗證方法表現，未來可進一步應用於真實時間序列資料，例如交通流量與氣象資料、金融市場資料或政策干預資料，以檢驗方法在實務情境中的可行性。特別是當不同工具變量只在不同時間區段或不同資料來源中可得時，本文方法相較於傳統 union IV 方法應更具應用價值。

其次，本文目前主要以估計誤差作為評估指標，未來可進一步發展對應的統計推論方法。例如，可探討如何為 sequential projected IV estimator 建立有效的標準誤、信賴區間或假設檢定程序。由於每一輪子實驗僅提供低維 projected estimate，如何將多輪估計不確定性整合為 full-dimensional parameter 的推論結果，仍是一個值得深入研究的問題。

第三，本文目前的 sequential selection rule 主要根據 projection space 的互補性進行設計。未來可進一步比較其他子集合選擇準則，例如基於第一階段強度、估計變異、資訊準則或子模組最佳化方法的選擇策略。不同選擇準則可能在 finite-sample setting 下產生不同表現，因此如何在工具變量相關性、外生性與投影空間覆蓋之間取得平衡，是未來可延伸的重要方向。

第四，本文雖已檢驗不同時間序列依賴強度下的方法表現，但仍限於平穩時間序列設定。未來可進一步考慮更複雜的動態結構，例如非平穩時間序列、結構轉變、長記憶過程或高維 VAR 模型。在這些設定下，工具變量子集合的可識別資訊可能隨時間變化，如何穩定地整合多輪 projected estimates 將成為更具挑戰性的問題。

最後，本文目前將 weak instrument 問題排除於主要研究範圍之外，聚焦於工具變量維度不足下的 projected reconstruction。未來可進一步結合 weak-IV robust inference，例如 Anderson–Rubin 類型的反演檢定或其他弱工具變量穩健方法，探討在工具變量同時具有維度不足與強度不足時，如何進行穩健的因果效果估計與推論。此方向將有助

於將本文方法推廣至更一般且更接近實務的工具變量時間序列問題。

# 參考文獻


[1] E. Ailer, J. Hartford, and N. Kilbertus, "Sequential underspecified instrument selection for cause-effect estimation," in *Proceedings of the 40th International Conference on Machine Learning*, ser. ICML'23. JMLR.org, 2023.

[2] N. Thams, R. Søndergaard, S. Weichwald, and J. Peters, "Identifying causal effects using instrumental time series: nuisance iv and correcting for the past," *J. Mach. Learn. Res.*, vol. 25, no. 1, Jan. 2024.

[3] P. G. Wright, *The Tariff on Animal and Vegetable Oils*. New York: The Macmillan Company, 1928.

[4] R. L. Basmann, "A generalized classical method of linear estimation of coefficients in a structural equation," *Econometrica*, vol. 25, no. 1, pp. 77–83, 1957.

[5] J. D. Sargan, "The estimation of economic relationships using instrumental variables," *Econometrica*, vol. 26, no. 3, pp. 393–415, 1958.

[6] L. P. Hansen, "Large sample properties of generalized method of moments estimators," *Econometrica*, vol. 50, no. 4, pp. 1029–1054, 1982.

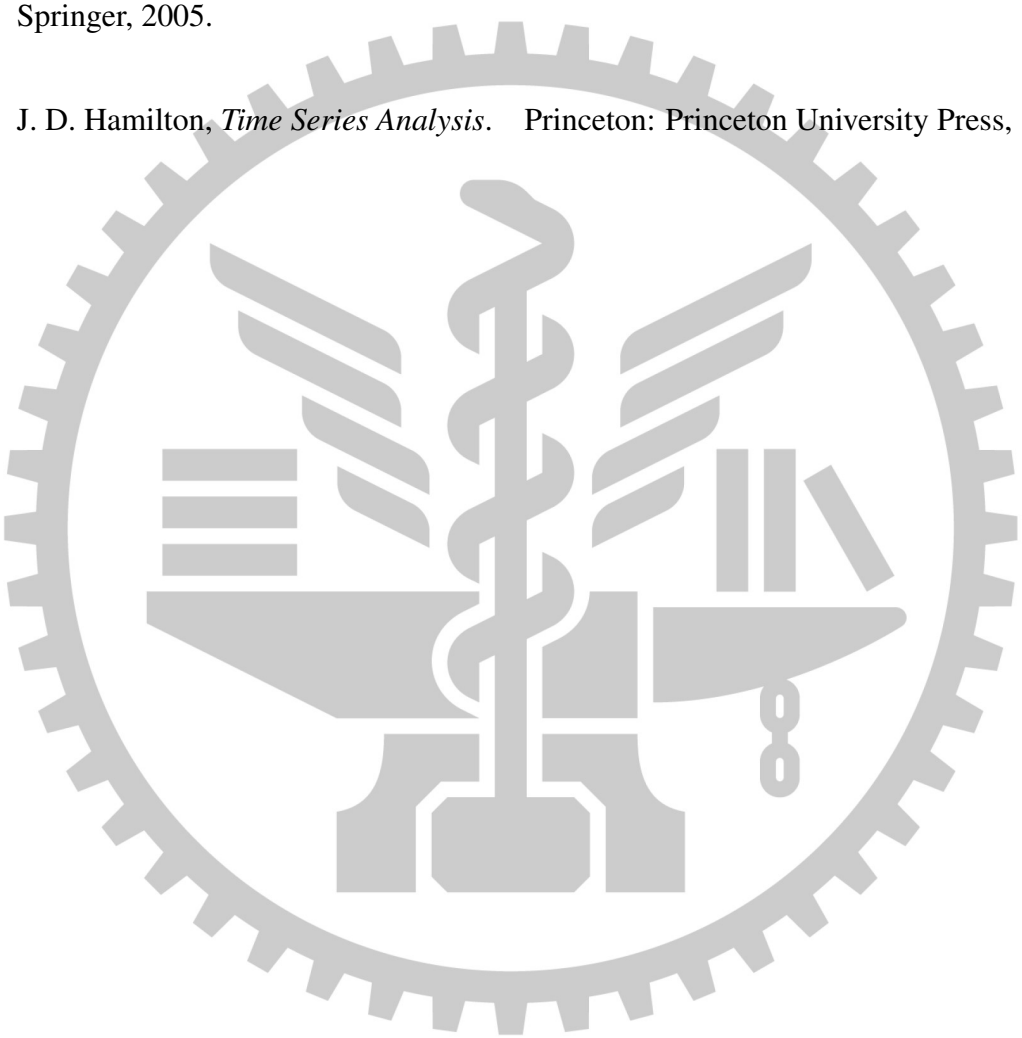
[7] G. W. Imbens and J. D. Angrist, "Identification and estimation of local average treatment effects," *Econometrica*, vol. 62, no. 2, pp. 467–475, 1994.

[8] J. D. Angrist and A. B. Krueger, “Instrumental variables and the search for identification: From supply and demand to natural experiments,” *Journal of Economic Perspectives*, vol. 15, no. 4, pp. 69–85, 2001.

[9] C. A. Sims, “Macroeconomics and reality,” *Econometrica*, vol. 48, no. 1, pp. 1–48, 1980.

[10] H. Lütkepohl, *New Introduction to Multiple Time Series Analysis*. Berlin Heidelberg: Springer, 2005.

[11] J. D. Hamilton, *Time Series Analysis*. Princeton: Princeton University Press, 1994.



# Appendix 附錄

## .1 資料示例表格

以下依序展示本文使用之反應變數 $Y_t$、解釋變數 $X_t$ 與三組工具變量資料 $I_1$、$I_2$、$I_3$ 的部分觀測值，以說明資料格式與欄位內容。各表皆依時間順序排列，並自各自資料中擷取一段連續且相對完整的時間區間作為範例。

Table 7: $Y_t$ 部分資料示例

| Timestamp | $Y_t$ | $Y_t$_% | target_flow | target_speed | target_occupancy |
|---|---|---|---|---|---|
| 2026-01-02T00:05:00Z | 0.0242 | 2.4169 | 84 | 64.6 | 0.0313 |
| 2026-01-02T00:10:00Z | 0.0136 | 1.3595 | 69 | 65.3 | 0.0272 |
| 2026-01-02T00:15:00Z | 0.0347 | 3.4743 | 64 | 63.9 | 0.0276 |
| 2026-01-02T00:20:00Z | 0.0257 | 2.5680 | 64 | 64.5 | 0.0279 |
| 2026-01-02T00:25:00Z | 0.0483 | 4.8338 | 75 | 63.0 | 0.0311 |
| 2026-01-02T00:30:00Z | 0.0468 | 4.6828 | 49 | 63.1 | 0.0248 |
| 2026-01-02T00:35:00Z | 0.0287 | 2.8701 | 49 | 64.3 | 0.0225 |
| 2026-01-02T00:40:00Z | 0.0242 | 2.4169 | 61 | 64.6 | 0.0264 |
| 2026-01-02T00:45:00Z | 0.0272 | 2.7190 | 43 | 64.4 | 0.0221 |
| 2026-01-02T00:50:00Z | 0.0272 | 2.7190 | 63 | 64.4 | 0.0257 |
| 2026-01-02T00:55:00Z | 0.0272 | 2.7190 | 50 | 64.4 | 0.0248 |
| 2026-01-02T01:00:00Z | 0.0287 | 2.8701 | 47 | 64.3 | 0.0239 |
| 2026-01-02T01:05:00Z | 0.0166 | 1.6616 | 55 | 65.1 | 0.0253 |
| 2026-01-02T01:10:00Z | 0.0196 | 1.9637 | 43 | 64.9 | 0.0216 |
| 2026-01-02T01:15:00Z | 0.0302 | 3.0211 | 41 | 64.2 | 0.0213 |
| 2026-01-02T01:20:00Z | 0.0181 | 1.8127 | 50 | 65.0 | 0.0227 |
| 2026-01-02T01:25:00Z | 0.0227 | 2.2659 | 49 | 64.7 | 0.0254 |
| 2026-01-02T01:30:00Z | 0.0227 | 2.2659 | 51 | 64.7 | 0.0234 |
| 2026-01-02T01:35:00Z | 0.0136 | 1.3595 | 57 | 65.3 | 0.0246 |
| 2026-01-02T01:40:00Z | 0.0211 | 2.1148 | 37 | 64.8 | 0.0206 |

Table 8: $X_t$ 部分資料示例

| Timestamp | 316922_flow | 316922_speed | 318102_flow | 318102_speed | 317802_flow | 317141_flow | 314230_flow |
|---|---|---|---|---|---|---|---|
| 2026-01-02T00:05:00Z | 25 | 66.6 | 66 | 68.5 | 34 | 39 | 18 |
| 2026-01-02T00:10:00Z | 30 | 66.6 | 65 | 68.2 | 34 | 34 | 20 |
| 2026-01-02T00:15:00Z | 21 | 66.7 | 60 | 68.1 | 39 | 47 | 21 |
| 2026-01-02T00:20:00Z | 10 | 67.0 | 59 | 68.1 | 36 | 36 | 24 |
| 2026-01-02T00:25:00Z | 15 | 66.0 | 56 | 67.9 | 36 | 39 | 17 |
| 2026-01-02T00:30:00Z | 18 | 66.9 | 53 | 67.9 | 38 | 42 | 19 |
| 2026-01-02T00:35:00Z | 17 | 66.9 | 53 | 68.0 | 34 | 34 | 19 |
| 2026-01-02T00:40:00Z | 9 | 67.2 | 52 | 67.8 | 34 | 20 | 14 |
| 2026-01-02T00:45:00Z | 10 | 65.7 | 49 | 67.8 | 34 | 30 | 13 |
| 2026-01-02T00:50:00Z | 12 | 66.1 | 46 | 67.8 | 36 | 39 | 13 |
| 2026-01-02T00:55:00Z | 12 | 65.5 | 44 | 67.8 | 38 | 33 | 12 |
| 2026-01-02T01:00:00Z | 17 | 66.2 | 42 | 67.8 | 34 | 33 | 12 |
| 2026-01-02T01:05:00Z | 16 | 66.6 | 43 | 67.9 | 34 | 20 | 8 |
| 2026-01-02T01:10:00Z | 12 | 66.7 | 42 | 67.9 | 34 | 31 | 14 |
| 2026-01-02T01:15:00Z | 17 | 66.4 | 40 | 68.0 | 34 | 25 | 9 |
| 2026-01-02T01:20:00Z | 9 | 67.1 | 40 | 68.0 | 34 | 32 | 8 |
| 2026-01-02T01:25:00Z | 10 | 66.9 | 38 | 67.7 | 38 | 17 | 8 |
| 2026-01-02T01:30:00Z | 10 | 67.0 | 38 | 67.8 | 36 | 34 | 15 |
| 2026-01-02T01:35:00Z | 7 | 66.8 | 39 | 67.9 | 38 | 23 | 14 |
| 2026-01-02T01:40:00Z | 7 | 66.8 | 39 | 67.9 | 34 | 17 | 12 |

Table 9: $I_1$ 部分資料示例

| time | precip._5min | sea_level_pressure | pressure_3hr_change | sky_baseht |
|---|---|---|---|---|
| 2026-01-28T02:53:00Z | – | 1025.5 | 0.8 | – |
| 2026-01-28T03:53:00Z | – | 1026.1 | – | 3353 |
| 2026-01-28T04:53:00Z | – | 1027.0 | – | 1829 |
| 2026-01-28T05:53:00Z | – | 1028.0 | 2.5 | 1829 |
| 2026-01-28T06:17:00Z | – | – | – | 1829 |
| 2026-01-28T06:28:00Z | – | – | – | 1829 |
| 2026-01-28T06:53:00Z | – | 1027.1 | – | 2134 |
| 2026-01-28T07:53:00Z | – | 1028.1 | – | 1676 |
| 2026-01-28T08:53:00Z | – | 1028.3 | 0.3 | 1463 |
| 2026-01-28T09:53:00Z | – | 1028.6 | – | 1250 |
| 2026-01-28T10:53:00Z | – | 1028.7 | – | 1158 |
| 2026-01-28T11:53:00Z | – | 1028.9 | 0.6 | 1219 |
| 2026-01-28T12:53:00Z | – | 1029.0 | – | 1280 |
| 2026-01-28T13:53:00Z | – | 1029.4 | – | – |
| 2026-01-28T14:53:00Z | – | 1029.5 | 0.6 | – |
| 2026-01-28T15:53:00Z | – | 1029.8 | – | – |
| 2026-01-28T16:53:00Z | – | 1030.2 | – | – |
| 2026-01-28T17:53:00Z | – | 1030.4 | 0.6 | – |
| 2026-01-28T18:53:00Z | – | 1030.5 | – | 427 |
| 2026-01-28T19:53:00Z | – | 1029.3 | – | 366 |

Table 10: $I_2$ 部分資料示例

| time | altimeter | rel. humidity | temperature | dew_point | visibility | wind_speed |
|---|---|---|---|---|---|---|
| 2026-01-01T00:15:00Z | 1015.9 | 100 | 9 | 9 | 9.656 | 2.6 |
| 2026-01-01T00:35:00Z | 1015.6 | 100 | 9 | 9 | 9.656 | 2.6 |
| 2026-01-01T00:55:00Z | 1015.6 | 100 | 9 | 9 | 11.265 | 2.6 |
| 2026-01-01T01:15:00Z | 1015.2 | 100 | 9 | 9 | 8.047 | 3.1 |
| 2026-01-01T01:35:00Z | 1015.2 | 100 | 9 | 9 | 6.437 | 2.1 |
| 2026-01-01T01:55:00Z | 1015.6 | 100 | 9 | 9 | 4.828 | 2.1 |
| 2026-01-01T02:15:00Z | 1015.6 | 100 | 9 | 9 | 4.023 | 2.6 |
| 2026-01-01T02:35:00Z | 1015.6 | 100 | 9 | 9 | 3.219 | 2.6 |
| 2026-01-01T02:55:00Z | 1015.6 | 100 | 9 | 9 | 3.219 | 2.1 |
| 2026-01-01T03:15:00Z | 1015.6 | 100 | 9 | 9 | 3.219 | 1.5 |
| 2026-01-01T03:35:00Z | 1015.6 | 100 | 9 | 9 | 3.219 | 1.5 |
| 2026-01-01T03:55:00Z | 1015.6 | 100 | 9 | 9 | 3.219 | 2.1 |
| 2026-01-01T04:15:00Z | 1015.6 | 94 | 9 | 8 | 2.816 | 2.1 |
| 2026-01-01T04:35:00Z | 1015.2 | 100 | 9 | 9 | 2.816 | 2.6 |
| 2026-01-01T04:55:00Z | 1015.2 | 100 | 9 | 9 | 2.816 | 2.1 |
| 2026-01-01T05:15:00Z | 1015.2 | 94 | 9 | 8 | 2.816 | 2.6 |
| 2026-01-01T05:35:00Z | 1015.2 | 100 | 9 | 9 | 3.219 | 2.6 |
| 2026-01-01T05:55:00Z | 1015.2 | 100 | 9 | 9 | 4.023 | 2.1 |
| 2026-01-01T06:15:00Z | 1015.2 | 100 | 9 | 9 | 4.023 | 2.1 |
| 2026-01-01T06:35:00Z | 1014.9 | 100 | 9 | 9 | 4.023 | 2.1 |

Table 11: $I_3$ 部分資料示例

| time | wind_direction | ceiling_height | sky_baseht_1 | wind_gust | sky_baseht_3 |
|---|---|---|---|---|---|
| 2026-01-03T14:53:00Z | 160 | 2743 | 1829 | 10.8 | – |
| 2026-01-03T15:53:00Z | 150 | 2591 | 1494 | – | – |
| 2026-01-03T16:53:00Z | 160 | 1524 | 1189 | 10.8 | 3048 |
| 2026-01-03T17:14:00Z | 160 | 1189 | 366 | 17.0 | 2286 |
| 2026-01-03T17:24:00Z | 170 | 2286 | 366 | 12.4 | 3048 |
| 2026-01-03T17:53:00Z | 170 | 1524 | 305 | 10.3 | 2286 |
| 2026-01-03T18:05:00Z | 160 | 366 | 366 | 11.8 | 2286 |
| 2026-01-03T18:41:00Z | 160 | 1524 | 366 | 12.4 | 1829 |
| 2026-01-03T18:53:00Z | 160 | 1829 | 366 | 12.9 | 1829 |
| 2026-01-03T19:08:00Z | 220 | 1097 | 427 | 16.5 | 1676 |
| 2026-01-03T19:11:00Z | 210 | 884 | 427 | 16.5 | 1494 |
| 2026-01-03T19:13:00Z | 210 | 792 | 427 | 16.5 | 1676 |
| 2026-01-03T19:32:00Z | 220 | 518 | 518 | – | 1311 |
| 2026-01-03T19:53:00Z | 240 | 427 | 427 | – | 1311 |
| 2026-01-03T20:23:00Z | 240 | 427 | 213 | 10.8 | 1128 |
| 2026-01-03T20:31:00Z | 220 | 427 | 213 | 14.4 | 1829 |
| 2026-01-03T20:35:00Z | 210 | 1128 | 152 | 14.4 | 1829 |
| 2026-01-03T20:45:00Z | 200 | – | 152 | 13.4 | 2134 |
| 2026-01-03T21:53:00Z | 190 | 1128 | 823 | 12.4 | – |
| 2026-01-03T22:53:00Z | 200 | 1067 | 1067 | 14.4 | – |